Ai chấm máy chấm?

Đánh giá tính trung thực mức mệnh đề cho hệ hỏi đáp GraphRAG tiếng Việt

Hà Văn Vinh

Xử lý ngôn ngữ tự nhiên nâng cao · Đồ án P4 ViKAG-Faith

CÂU TRẢ LỜI CỦA AI, TÁCH THÀNH TỪNG Ý

được quảng cáo trên **Facebook**

SUPPORTED

tổng tiền phạt là **8 triệu đồng**

CONTRADICTED

được quảng cáo trên **Instagram**

UNSUPPORTED

VẤN ĐỀ

AI trả lời trôi chảy, nhưng một con số sai là đủ gây hậu quả

AI NÓI

Luật sửa đổi Luật Dược trình Quốc hội **tháng 10/2025**

CONTRADICTED

VĂN BẢN GHI

Tờ trình: trình Quốc hội **tháng 10 năm 2022**

Mốc 10/2025 là của Luật An toàn thực phẩm.

Máy chấm tự động được dùng để bắt lỗi kiểu này. Nhưng máy chấm có đáng tin với tiếng Việt không?

VẤN ĐỀ

Điểm tổng không cho biết sai ở đâu, và máy chấm chủ yếu được thử trên tiếng Anh

1 điểm

GraphRAG/KAG tiếng Việt hiện được chấm bằng F1 hoặc một điểm LLM-judge cho cả câu trả lời. Không điểm nào chỉ ra ý nào bịa thêm hay mâu thuẫn.

0,7554 → 0,6823

ViHERMES (ACIIDS 2026): bỏ module kiểm chứng làm điểm judge giảm. Kiểm chứng quan trọng, nhưng chính công cụ kiểm chứng chưa được đo.

Tiếng Anh

RAGAS, LLM-judge, SelfCheckGPT chủ yếu được kiểm định trên tiếng Anh, chưa ở mức từng ý cho tiếng Việt.

CÂU HỎI NGHIÊN CỨU

Đề tài không xây chatbot mới, mà kiểm tra các máy chấm

RQ1

Metric có sẵn (RAGAS, LLM-judge, SelfCheckGPT, NLI) khớp với nhãn chuẩn đến đâu?

RQ2

Thông tin đồ thị, rule số/ngày, fine-tune bằng dữ liệu tổng hợp có giúp verifier không?

RQ3

Verify-then-revise giảm claim sai bao nhiêu, có làm giảm chất lượng trả lời không?

ĐÓNG GÓP

Quy trình: đánh giá mức claim tái lập được trên ViHERMES

Dữ liệu: ViFaithKAG pilot: 284 claim silver, 165 claim nhãn người

Meta-evaluation: 24 biến thể metric và ablation đồ thị, rule, số vòng sửa

Độ tin cậy nhãn: nhãn LLM so với người: thứ hạng metric đổi theo bộ nhãn

CÁCH LÀM

Từ 100 câu hỏi đến 284 claim trong mẫu, 165 claim có người gán

100 câu hỏi ViHERMES, 20 câu mỗi mức 1–5 hop

› **200** câu trả lời từ Naive RAG và GraphRAG

› **610** claim tách bằng Qwen2.5-3B

› **80** câu trả lời vào mẫu gán nhãn

› **284** claim trong mẫu (15 claim lỗi bị loại, còn 269)

› **165** claim có nhãn người

Hai hệ Naive RAG lấy 8 đoạn, GraphRAG lấy 4 hạt giống rồi lan truyền trên đồ thị. Cùng BM25 + bge-m3, cùng Qwen2.5-3B, cùng 6.000 ký tự ngữ cảnh.

Bằng chứng Đoạn truy xuất cộng đoạn vàng của ViHERMES, kèm tên văn bản, số hiệu, quan hệ từ đồ thị. Mọi máy chấm và người gán nhìn cùng một tập này.

Ba nhãn SUPPORTED | CONTRADICTED | UNSUPPORTED

CÁCH LÀM

Các máy chấm được so sánh trên cùng một tập bằng chứng

Máy chấm	Cách làm	Biến thể
RAGAS	Tái hiện 2 prompt gốc, chấm cả câu trả lời	Qwen2.5 3B, 7B, 14B
LLM-judge	LLM gán 3 nhãn cho từng claim	Qwen2.5 3B, 7B, 14B
NLI mDeBERTa-v3	Zero-shot trên cửa sổ 900 ký tự, ngưỡng chọn trên tập dev	V1 đoạn văn · V2 thêm đồ thị
NLI fine-tune	12.000 cặp ViNLI + 3.328 cặp tổng hợp (đổi số, ngày, phủ định)	Ablation: chỉ ViNLI
Rule	So khớp số, ngày, số hiệu văn bản	Riêng lẻ, hoặc thêm vào NLI
SelfCheckGPT	3 mẫu nhiệt độ 0,7, không nhìn bằng chứng	Mốc so sánh

$$\text{GGF} = \frac{\text{số claim supported}}{\text{tổng số claim}}, \qquad \text{CR} = \frac{\text{số claim contradicted}}{\text{tổng số claim}}, \qquad \text{UR} = \frac{\text{số claim unsupported}}{\text{tổng số claim}}$$

CÁCH LÀM

Nhãn chính do Claude gán, người kiểm tra mù lại 165 claim

Nhãn silver của 269 claim



Lượt	Cách chọn	Claim	Trùng Claude	κ
C	phân tầng, xem toàn đoạn	60	60%	0,29
G, H, I, J	ngẫu nhiên, xem 4 câu	105	69%	0,30
Gộp		**165**	**65%**	**0,29**

Lượt A, D, E bị loại: duyệt có gợi ý hoặc file không tạo qua trang gán nhãn.

58%

bộ dữ liệu có nhãn người (165/284)

Người gán không thấy nhãn hay lý do của Claude và không biết câu trả lời thuộc hệ nào.

Judge tốt nhất vẫn bỏ sót khoảng 1/3 số ý sai



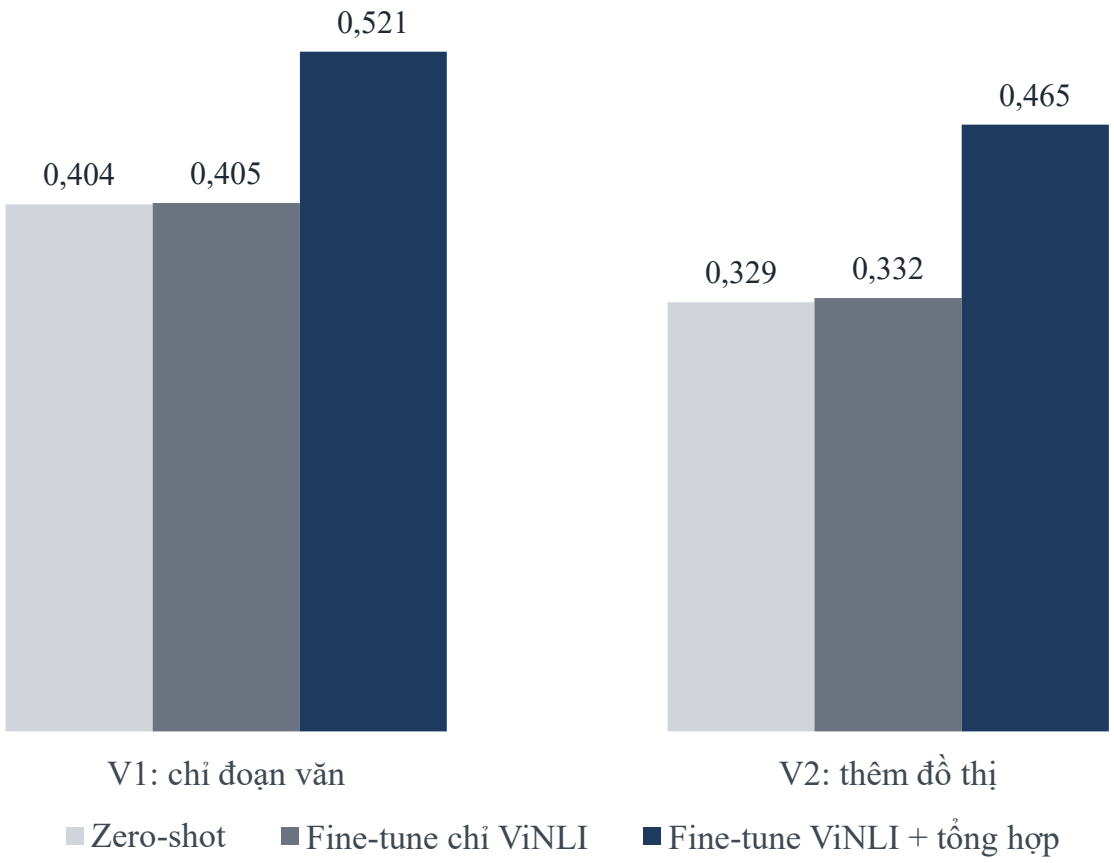
Mỗi ô là một ý sai trong tập test. Ô đậm: Judge 7B bắt được.

Máy chấm	Bắt được	Báo nhầm	Macro-F1
Judge 7B	**41/64**	**22/153**	**0,476**
NLI fine-tune V1	34/65	37/153	0,521
Judge 3B	26/63	19/151	0,439
NLI zero-shot V1	21/65	38/153	0,404
Judge 14B	45/65	26/153	0,541

Theo nhãn silver. Báo nhầm là số ý đúng bị cho là sai. SelfCheckGPT đạt 0,409 dù không nhìn bằng chứng, ngang NLI zero-shot.

Chấm cả câu trả lời: RAGAS khớp nhất với điểm chuẩn, tăng theo mô hình: $\rho = 0{,}258$ (3B), 0,484 (7B), 0,644 (14B).

Dữ liệu tự tạo nâng điểm theo nhãn Claude, thông tin đồ thị làm kém đi



+ Dữ liệu tổng hợp

+0,117 so với zero-shot (KTC 0,03–0,20). Bỏ dữ liệu này chỉ còn +0,002. 20.000 cặp: 0,572, không hơn có ý nghĩa.

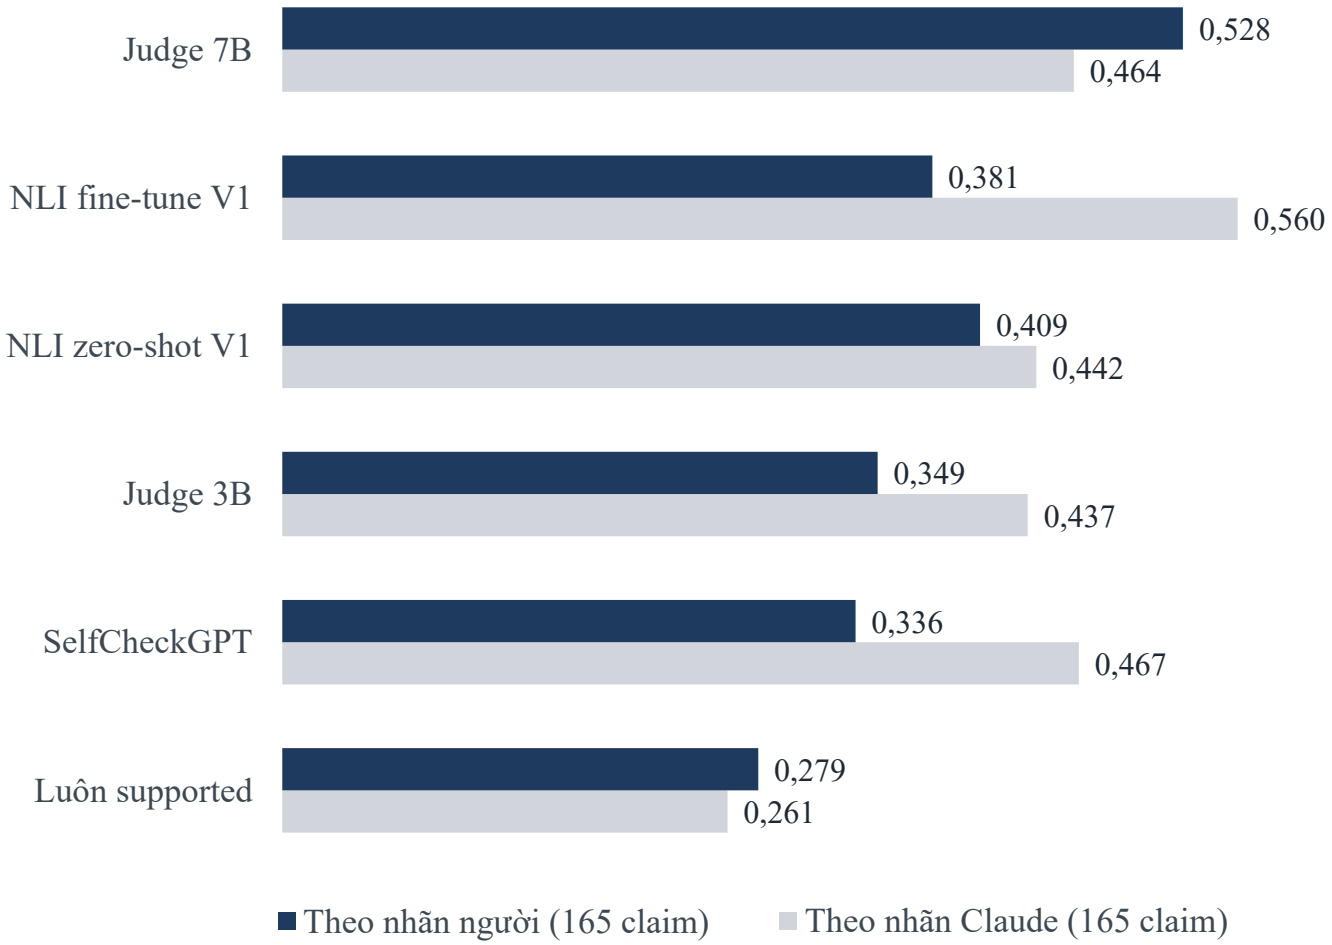
− Thông tin đồ thị

0,404 → 0,329 khi nhét mọi thông tin đồ thị. Triple nối theo claim đạt 0,423, nhưng theo nhãn người chỉ 0,328.

= Rule số, ngày

0,404 → 0,401: nhiều lỗi nằm ở chủ thể, không ở con số.

Đổi sang nhãn người, bảng xếp hạng đổi theo



0,528

Judge 7B: cao nhất theo nhãn người

0,560 → 0,381

Fine-tune tụt xuống, không hơn zero-shot (0,409)

Claude trùng người 65%, $\kappa = 0{,}29$, khắt khe hơn người: 29/59 ý Claude cho là sai, người gán supported. Tương quan thứ hạng $\rho = 0{,}46$.

RQ3 · VERIFY-THEN-REVISE

Tự sửa giảm ý sai, nhưng AI chủ yếu xóa ý thay vì sửa cho đúng

GGF theo judge 7B	0,755 → **0,830**
Claim mâu thuẫn (%)	8,8 → **4,1**
Token F1	0,595 → **0,563**
Claim mỗi câu	3,55 → **2,44**

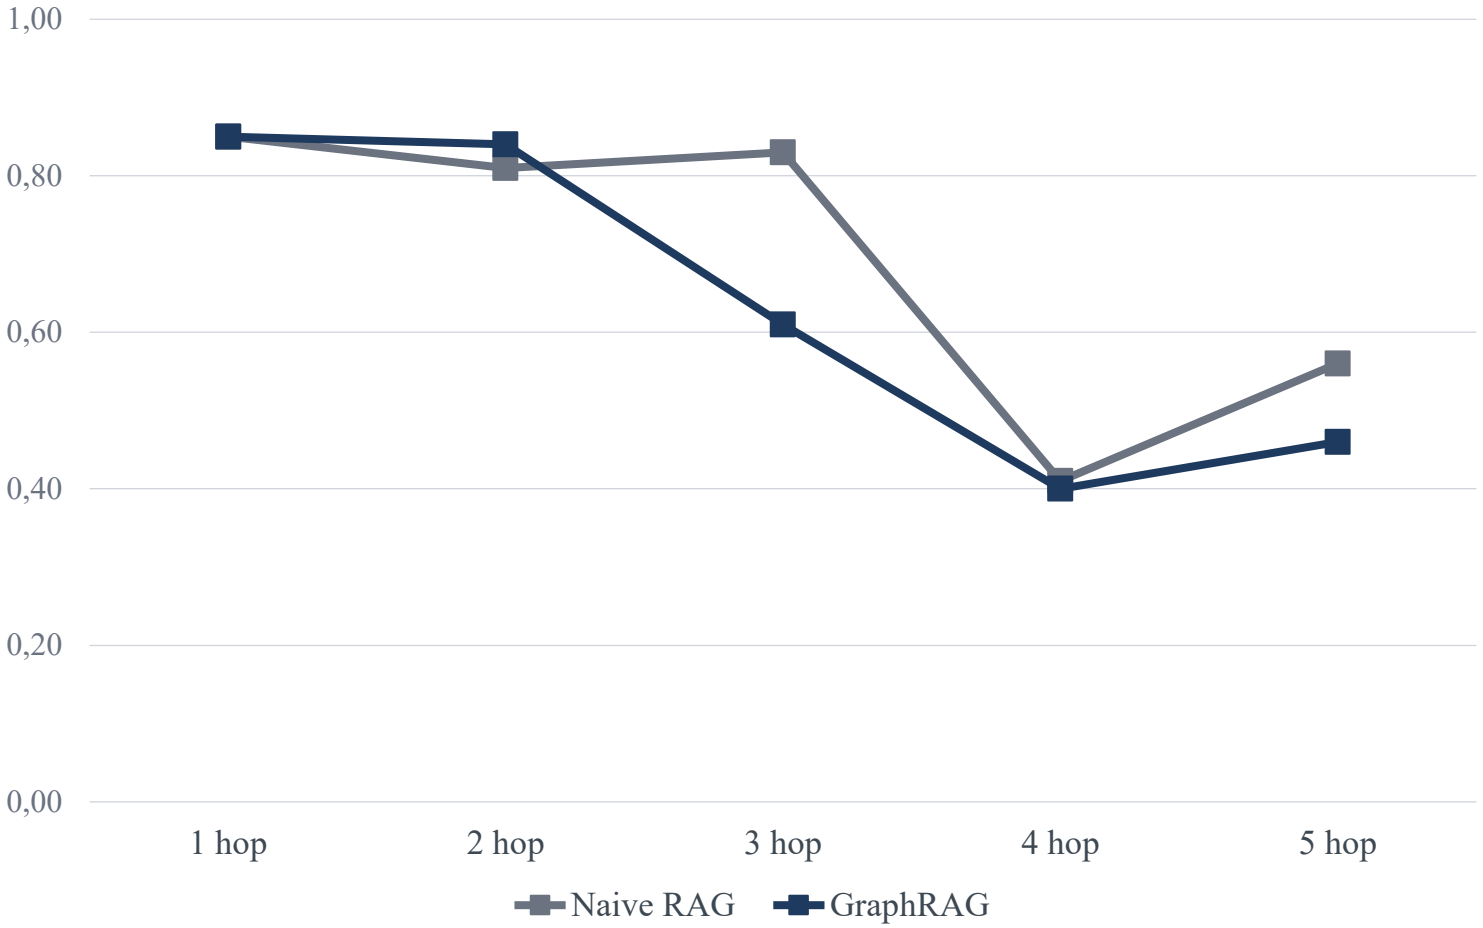
42/80 câu được sửa. p(GGF) = 0,014, p(F1) = 0,001. 7 câu thành "không tìm thấy thông tin".

Vòng sửa	GGF	CR	F1	Recall
0	0,755	0,088	0,595	0,591
1	0,801	0,059	0,569	0,545
2	0,830	0,041	0,563	0,535

Vòng 1 cho phần lớn mức tăng. EM = 0 ở mọi cấu hình vì đáp án ViHERMES dài khoảng 115 từ. GGF do chính judge 7B chấm lại nên là giới hạn trên.

HAI HỆ

Naive RAG và GraphRAG ngang nhau ($p = 0{,}191$), khó là ở câu nhiều hop



0,694 · 0,638

GGF trung bình của Naive RAG và GraphRAG

47,0% · 47,9%

recall đoạn vàng của hai hệ: đồ thị phát hành khá thô

GGF 0,402–0,558 ở câu 4–5 hop, so với 0,854 ở câu 1 hop.

HẠN CHẾ

Sáu giới hạn cần đọc kèm mọi con số

Giới hạn	Cụ thể	Giảm thiểu
Nhãn chuẩn là silver	Claude trùng người 65%	Báo cáo song song theo nhãn người
Một người gán	Không phải chuyên gia pháp lý; lượt nhanh chỉ xem 4 câu	Hai người gán, đo κ người–người
Quy mô nhỏ	2 hệ, 284 claim, judge lớn nhất 14B	KTC bootstrap, kiểm định ghép cặp
Ngưỡng kém ổn định	Chọn trên 51 claim; theo nhãn người cũng không cải thiện	Thêm nhãn người, so thêm AUROC
Revise tự chấm	Judge vừa gắn cờ vừa chấm lại	Chấm bằng người hoặc metric độc lập
Đồ thị dạng văn bản	Triple nối dạng văn bản; chưa có ViEduReg, toán tử Verify KAG	Verifier đọc triple có cấu trúc

Điểm của máy chấm chỉ là tín hiệu tham khảo, văn bản pháp luật vẫn cần người kiểm tra

RQ1 Judge 7B (0,528 theo người) và RAGAS tốt nhất, chỉ khớp mức trung bình; judge 14B không hơn có ý nghĩa.

RQ2 Dữ liệu tổng hợp giúp mDeBERTa theo silver, không giữ được theo người; 20.000 cặp không hơn có ý nghĩa. XLM-R fine-tune tăng theo người (0,463) nhưng báo nhầm nhiều. Đồ thị, triple và rule chưa giúp được.

RQ3 Sửa giảm claim sai bằng cách xóa nội dung: đây là đánh đổi, chưa phải cải thiện thuần.

Cảm ơn thầy cô và các bạn đã lắng nghe

Hà Văn Vinh · Mã nguồn và dữ liệu: github.com/vinhha195-oss/vikag-faith