ViKAG-Faith: Đánh giá tính trung thực mức mệnh đề cho hệ hỏi đáp GraphRAG tiếng Việt

Báo cáo thực nghiệm quy mô pilot · Dữ liệu ViHERMES (văn bản pháp quy y tế) · 01/11/2026

Tóm tắt. Báo cáo đánh giá các metric faithfulness tự động cho hệ hỏi đáp tiếng Việt dùng truy xuất trên đồ thị tri thức. Hai hệ (Naive RAG hybrid và GraphRAG dùng graph pháp quy của ViHERMES) cùng dùng Qwen2.5-3B trả lời 100 câu hỏi ViHERMES (20 câu mỗi mức 1–5 hop). Câu trả lời được tách thành claim; 284 claim của 80 câu trả lời được gán nhãn supported / contradicted / unsupported (nhãn silver do Claude gán; một mẫu kiểm định mù 60 claim do người gán cho $\kappa = 0{,}29$). Trên tập test (218 claim, nhãn silver), verifier mDeBERTa fine-tune trên ViNLI + cặp tổng hợp từ corpus đạt macro-F1 cao nhất (0,521), ngang LLM-judge Qwen2.5-7B (0,476; chênh 0,047, KTC 95% [-0,06; 0,16]) và hơn rõ verifier zero-shot (0,404). Ablation bỏ dữ liệu tổng hợp đưa kết quả về mức zero-shot (0,405). Tuy vậy, trên mẫu kiểm định mù do người gán, verifier fine-tune tụt xuống dưới judge-7B, nên ưu thế này có thể đến từ việc học theo nhãn silver. Ở mức câu trả lời, **RAGAS faithfulness (7B)** tương quan cao nhất với nhãn chuẩn (Spearman $\rho = 0{,}484$). SelfCheckGPT (không dùng bằng chứng) đạt 0,409. Thêm thông tin graph dạng văn bản vào đầu vào NLI làm giảm kết quả, và rule số/ngày không cải thiện thêm. Vòng *kiểm chứng rồi sửa* (judge 7B gắn cờ, bộ sinh viết lại) nâng GGF từ 0,755 lên 0,830 (Wilcoxon $p = 0{,}014$, đo bằng chính judge đó) nhưng giảm token F1 từ 0,595 xuống 0,563: câu trả lời trung thực hơn chủ yếu vì ngắn hơn. Naive RAG và GraphRAG không khác nhau có ý nghĩa (GGF 0,694 và 0,638, $p = 0{,}191$).

1. Giới thiệu

Hệ GraphRAG/KAG tiếng Việt hiện thường được chấm bằng F1 hoặc một điểm LLM-judge cho cả câu trả lời. Cách chấm này không chỉ ra mệnh đề nào trong câu trả lời là bịa thêm hay mâu thuẫn với bằng chứng, trong khi với văn bản pháp quy, một con số hay một ngày hiệu lực sai là đủ gây hậu quả. Đề tài là bản rút gọn của Project 4 trong đề cương ViKAG-Faith, theo đúng ba câu hỏi nghiên cứu của đề cương:

- **RQ1.** Các metric faithfulness hiện có (RAGAS, LLM-judge, SelfCheckGPT) khớp với nhãn chuẩn đến mức nào trên tiếng Việt?
- **RQ2.** Verifier dùng bằng chứng graph (văn bản nguồn, số hiệu, quan hệ sửa đổi/dẫn chiếu), rule kiểm tra số/ngày và fine-tune trên dữ liệu tổng hợp từ corpus có phát hiện claim sai tốt hơn verifier NLI chung không?

- **RQ3.** Vòng *kiểm chứng rồi sửa* (verify-then-revise) có giảm hallucination mà không làm giảm chất lượng trả lời không?

Ngoài ra, mục 6.5 so sánh độ trung thực của Naive RAG và GraphRAG theo số hop.

2. Công trình liên quan

RAGAS (Es và cs., EACL 2024 Demo) định nghĩa faithfulness là tỉ lệ statement suy ra được từ ngữ cảnh. SemEval-2024 SHROOM và Mu-SHROOM nghiên cứu phát hiện hallucination; DSC2025 ViHallu đánh giá hallucination tiếng Việt nhưng không gắn với KG. ViHERMES (Nguyen và cs., ACIIDS 2026) xây benchmark multi-hop về văn bản pháp quy y tế và graph cấu trúc pháp lý, cho thấy module Auditor kiểm chứng nâng điểm LLM-judge từ 0,6823 lên 0,7554. Các hệ GraphRAG như LightRAG, HippoRAG 2 và KAG (Liang và cs., WWW 2025) chưa được đánh giá faithfulness ở mức mệnh đề trên tiếng Việt. SelfCheckGPT (Manakul và cs., EMNLP 2023) phát hiện hallucination không cần bằng chứng, dựa trên độ nhất quán giữa các câu trả lời lấy mẫu. Verifier dùng mDeBERTa-v3-base huấn luyện NLI đa ngôn ngữ (XNLI có tiếng Việt).

3. Phương pháp

3.1 Hai hệ hỏi đáp được đánh giá

Cả hai hệ dùng cùng corpus (998 đoạn văn bản của ViHERMES, 471 văn bản), cùng bộ truy xuất hybrid (BM25 + bge-m3, trọng số 0,5), cùng ngân sách ngữ cảnh 6.000 ký tự và cùng bộ sinh Qwen2.5-3B-Instruct (nhiệt độ 0), nên khác biệt chỉ đến từ cách lấy ngữ cảnh:

- **Naive RAG:** 8 đoạn có điểm cao nhất, cắt theo ngân sách.
- **GraphRAG:** 4 đoạn hạt giống, sau đó lan truyền trên graph cấu trúc pháp lý của ViHERMES (quan hệ AMENDS, REPLACES, REFERS_TO, HAS_CLAUSE; 432 cạnh dẫn chiếu, 35 cạnh sửa đổi/thay thế), kèm danh sách quan hệ giữa các văn bản trong prompt.

3.2 Pipeline đánh giá

1. **Tách claim:** Qwen2.5-3B, prompt tiếng Việt kèm ví dụ; mỗi claim một vị từ chính, tự hiểu được.
2. **Tập bằng chứng** của mỗi câu trả lời = các đoạn hệ đã truy xuất ∪ các đoạn bằng chứng vàng của câu hỏi (ViHERMES cung cấp). Mọi metric và người gán nhãn đều dùng đúng tập này, nên chênh lệch giữa các metric phản ánh chất lượng metric.
3. **Nhãn:** supported (bằng chứng suy ra được), contradicted (bằng chứng nói ngược lại), unsupported (không đề cập / không đủ). Claim tách hỏng được đánh dấu "claim lỗi" và loại khỏi phép đo.
4. **Metric GGF** của một câu trả lời = tỉ lệ claim supported; CR, UR = tỉ lệ contradicted, unsupported.

3.3 Các metric tự động được so sánh

- **RAGAS faithfulness** tái hiện theo hai prompt gốc của thư viện (tách statement, rồi phán xét NLI), chạy với Qwen2.5-3B và 7B.
- **LLM-judge mức claim:** Qwen2.5-3B và 7B gán 3 nhãn cho các claim của đề tài.
- **Verifier NLI:** mDeBERTa-v3-base-xnli-multilingual, chạy trên cửa sổ 900 ký tự. Entailment lấy cửa sổ mạnh nhất; contradiction chỉ xét 2 cửa sổ trùng từ nhiều nhất với claim (vì NLI hay gán "contradiction" cho văn bản không liên quan). Hai biến thể đầu vào: **V1** chỉ đoạn văn; **V2** thêm tên văn bản, số hiệu và quan hệ lấy từ graph. Ngưỡng chọn trên tập dev (V1: τ_s=0,65, τ_c=0,45; V2: τ_s=0,15, τ_c=0,10).
- **Verifier fine-tune:** mDeBERTa huấn luyện thêm trên 12.000 cặp ViNLI + 3.328 cặp tổng hợp từ các đoạn *không* thuộc mẫu đánh giá (supported = câu gốc; contradicted = đổi con số/ngày hoặc thêm phủ định; unsupported = câu của đoạn khác cùng văn bản); 1 epoch, lr 5e-6, giữ checkpoint tốt nhất trên dev, float32. **Ablation:** cùng cấu hình nhưng chỉ dùng ViNLI. Ngưỡng của mỗi biến thể chọn trên tập dev.
- **SelfCheckGPT-NLI** (Manakul và cs., EMNLP 2023): sinh thêm 3 câu trả lời (nhiệt độ 0,7) từ cùng prompt và ngữ cảnh; claim được coi là đáng tin nếu các câu trả lời lấy mẫu kéo theo nó (trung bình xác suất entail/contradict của mDeBERTa). Phương pháp này không nhìn bằng chứng.
- **Rule số/ngày/số hiệu:** giá trị trong claim không có trong bằng chứng thì hạ nhãn supported thành unsupported; nếu câu bằng chứng tương ứng có giá trị cùng loại khác thì gán contradicted.

3.4 Verify-then-revise (RQ3)

Với mỗi câu trả lời trong mẫu, LLM-judge 7B (metric mức claim tốt nhất trong nhóm không cần huấn luyện) gắn cờ các claim unsupported hoặc contradicted. Bộ sinh Qwen2.5-3B nhận lại *đúng ngữ cảnh đã truy xuất*, câu trả lời cũ và danh sách claim bị gắn cờ, rồi viết lại câu trả lời (sửa hoặc bỏ các claim đó, chỉ dùng ngữ cảnh). Câu trả lời mới được tách claim và chấm lại bằng judge 7B trên cùng tập bằng chứng; tối đa 2 vòng. Câu trả lời không có claim nào bị gắn cờ được giữ nguyên.

4. Dữ liệu và gán nhãn

100 câu hỏi được lấy ngẫu nhiên phân tầng từ 1.561 câu của ViHERMES (seed 42). Mẫu gán nhãn gồm 40 câu (8 câu mỗi mức hop) × 2 hệ = 80 câu trả lời, 284 claim; 15 claim lỗi bị loại, còn 269 claim (supported 184, contradicted 42, unsupported 43). 20% số câu hỏi (51 claim) làm tập dev để chọn ngưỡng, phần còn lại (218 claim) làm tập test.

Quy trình gán nhãn: Claude gán toàn bộ claim kèm số đoạn bằng chứng và lý do (nhãn silver dùng cho mọi phép đo); người gán làm việc trên trang HTML ngoại tuyến, **không biết câu trả lời thuộc hệ nào** (mã claim được ẩn danh hóa).

4.1 Độ tin cậy của nhãn silver: kiểm định mù

Lượt duyệt đầu tiên (người duyệt xem nhãn gợi ý) xác nhận cả 284 claim mà không sửa nhãn nào (0 thay đổi) trong khoảng 10 phút; vì không có bằng chứng là đã đối chiếu thật, lượt này **không được dùng làm nhãn người**. Thay vào đó, một **mẫu kiểm định mù** gồm 60 claim (30 claim Claude gán supported, 15 contradicted, 15 unsupported, chọn ngẫu nhiên) được người gán lại từ đầu, không thấy nhãn hay lý do của Claude và không biết hệ sinh câu trả lời.

Kết quả: nhãn Claude trùng với người ở **60,0%** số claim, **Cohen's κ = 0,289** (đồng thuận thấp). Lệch chủ yếu theo một hướng: người gán supported cho phần lớn claim mà Claude gán contradicted hoặc unsupported, tức Claude khắt khe hơn người gán. Vì mẫu được chọn phân tầng theo nhãn Claude, tỉ lệ đồng ý được báo cáo riêng cho từng nhãn.

	Người: supported	Người: contradicted	Người: unsupported	Người đồng ý
Claude: supported	27	2	1	90,0%
Claude: contradicted	8	5	2	33,3%
Claude: unsupported	10	1	4	26,7%

Kiểm tra độ nhạy. Chấm lại các metric trên 60 claim này theo hai bộ nhãn: thứ hạng các metric thay đổi đáng kể (Spearman giữa hai bảng xếp hạng = 0,47, tính trên mọi phương pháp kể cả biến thể + rule). Thay đổi lớn nhất là verifier fine-tune V1: theo nhãn Claude nó đạt 0,519, gần judge-7B (0,499), nhưng theo nhãn người chỉ còn 0,452, thấp hơn judge-7B (0,525) và cả verifier zero-shot (0,510). Ngưỡng của verifier được chọn trên tập dev theo nhãn Claude, nên mô hình fine-tune có thể đã học cả cách gán nhãn khắt khe của Claude. Các phương pháp không có tham số học từ nhãn (judge, NLI zero-shot) giữ thứ hạng ổn định hơn. Vì vậy các so sánh ở mục 6 chỉ nên đọc như kết quả *theo nhãn silver*; với 60 claim, mẫu kiểm định đủ để cảnh báo nhưng chưa đủ để xếp hạng lại một cách chắc chắn.

Phương pháp	Macro-F1 theo nhãn người	Macro-F1 theo nhãn Claude	n
LLM-judge (Qwen2.5-7B)	0,525	0,499	60
NLI zero-shot, V1 (chỉ đoạn văn)	0,510	0,442	60
NLI fine-tune chỉ ViNLI, V1	0,501	0,373	60
NLI fine-tune, V1	0,452	0,519	60

LLM-judge (Qwen2.5-3B)	0,380	0,423	58
NLI fine-tune chỉ ViNLI, V2	0,358	0,312	60
NLI zero-shot, V2 (+ thông tin graph)	0,351	0,306	60
SelfCheckGPT-NLI (không dùng bằng chứng)	0,345	0,443	60
NLI fine-tune, V2	0,337	0,455	60
Chỉ rule số/ngày	0,290	0,233	60
Luôn đoán supported	0,286	0,222	60

Mẫu kiểm định bổ sung (lượt G, H, I, J). Thêm 120 claim chọn *ngẫu nhiên* (không phân tầng, 4 lượt 30 claim), không trùng lượt trên, được cùng người gán mù trên một trang rút gọn: mỗi màn hình một claim kèm 4 câu bằng chứng trùng từ nhiều nhất, có thể mở toàn bộ đoạn văn. 15 claim bị người gán đánh dấu khó hiểu hoặc là claim lỗi nên bị loại, còn 105 claim. Trên mẫu ngẫu nhiên này, Claude trùng với người ở 68,6% số claim ($\kappa = 0{,}301$). Đây là ước lượng ít thiên lệch hơn về độ chính xác chung của nhãn silver, nhưng với 105 claim, khoảng tin cậy còn rộng. Gộp lượt C với lượt G, H, I, J (165 claim): trùng 65,5%, $\kappa = 0{,}291$, tương quan thứ hạng metric $\rho = 0{,}46$. Theo nhãn người trên 165 claim, LLM-judge 7B vẫn tốt nhất, còn verifier fine-tune V1 chỉ ngang zero-shot: ưu thế của fine-tune ở mục 6.3 chỉ xuất hiện khi chấm theo nhãn Claude.

Phương pháp (gộp lượt C và G, H, I, J)	**Macro-F1 theo nhãn người**	**Macro-F1 theo nhãn Claude**	**n**
LLM-judge (Qwen2.5-7B)	0,528	0,464	165
NLI fine-tune, V1	0,381	0,560	165
NLI zero-shot, V1 (chỉ đoạn văn)	0,409	0,442	165
NLI fine-tune chỉ ViNLI, V1	0,395	0,438	165
LLM-judge (Qwen2.5-3B)	0,349	0,437	162
SelfCheckGPT-NLI (không dùng bằng chứng)	0,336	0,467	165
Luôn đoán supported	0,279	0,261	165

5. Thiết lập thực nghiệm

Thành phần	**Cấu hình**
Bộ sinh câu trả lời, tách claim	Qwen2.5-3B-Instruct (Ollama, Q4_K_M), nhiệt độ 0

Embedding	bge-m3
LLM-judge, RAGAS	Qwen2.5-3B và Qwen2.5-7B (Ollama), num_ctx 12.288
Verifier	MoritzLaurer/mDeBERTa-v3-base-xnli-multilingual-nli-2mil7; fine-tune float32, batch 4 × tích lũy 4, lr 5e-6, 1 epoch
SelfCheckGPT, verify-then-revise	3 mẫu, nhiệt độ 0,7 (seed 43–45); sửa tối đa 2 vòng, judge Qwen2.5-7B
Phần cứng	Google Colab T4 16GB cho mọi bước dùng mô hình; máy cá nhân cho dựng graph, phân tích, báo cáo
Thống kê	Macro-F1, AUROC (phát hiện claim không supported), Spearman/Kendall, KTC 95% bootstrap 1.000 lần (cả bootstrap ghép cặp cho hiệu số), Wilcoxon cặp

6. Kết quả

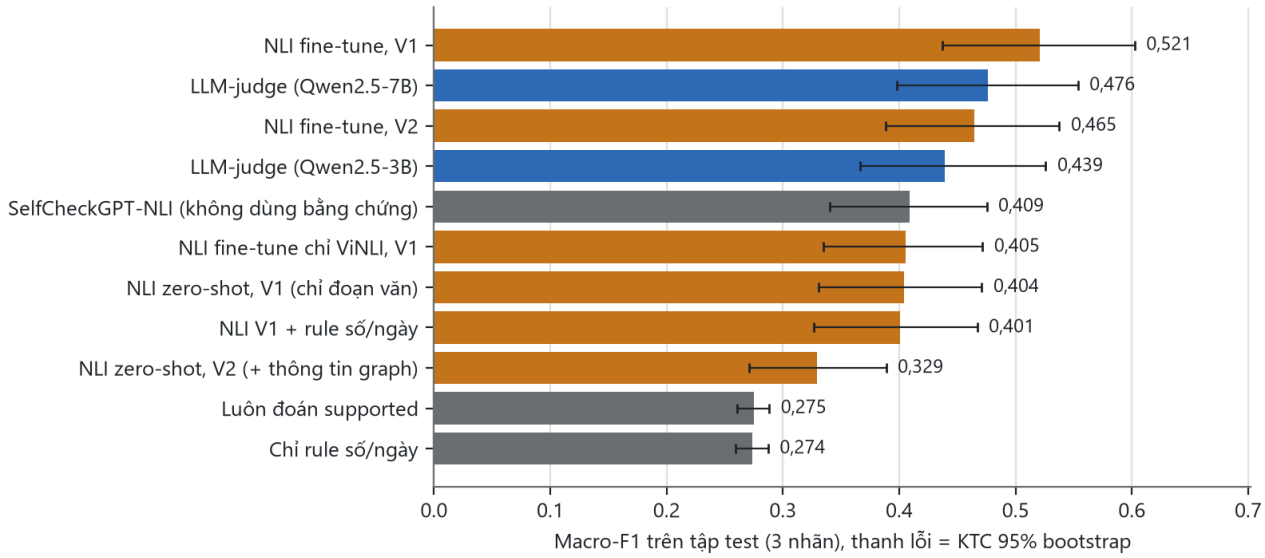
6.1 Chất lượng hỏi đáp của hai hệ (100 câu)

Hệ	Token F1 so với đáp án	Recall đoạn vàng trong ngữ cảnh	Tỉ lệ từ chối trả lời
Naive RAG	0,570	47,0%	22,0%
GraphRAG	0,563	47,9%	19,0%

Hai hệ gần như ngang nhau. Với cùng ngân sách ngữ cảnh, graph của ViHERMES phát hành kèm dữ liệu khá thô (mỗi đoạn chỉ gắn với văn bản gốc, ít cạnh sửa đổi), nên lan truyền trên graph thêm được ít đoạn vàng.

6.2 RQ1: metric tự động so với nhãn chuẩn

Mức claim. NLI fine-tune, V1 đạt macro-F1 cao nhất (0,521). Mốc "luôn đoán supported" đạt 0,275; mọi phương pháp vượt mốc này, trừ Chỉ rule số/ngày. Trong nhóm không cần huấn luyện, LLM-judge 7B tốt nhất (0,476), hơn judge 3B (0,439) và NLI zero-shot (0,404). SelfCheckGPT-NLI đạt 0,409, tương đương NLI zero-shot dù không nhìn bằng chứng; nhưng độ chính xác của nó thấp (0,463) vì nó hay coi claim đúng là đáng ngờ khi các câu trả lời lấy mẫu diễn đạt khác nhau. Ngay cả phương pháp tốt nhất vẫn còn xa mức thay được người: F1 cho nhãn contradicted và unsupported đều dưới 0,45.



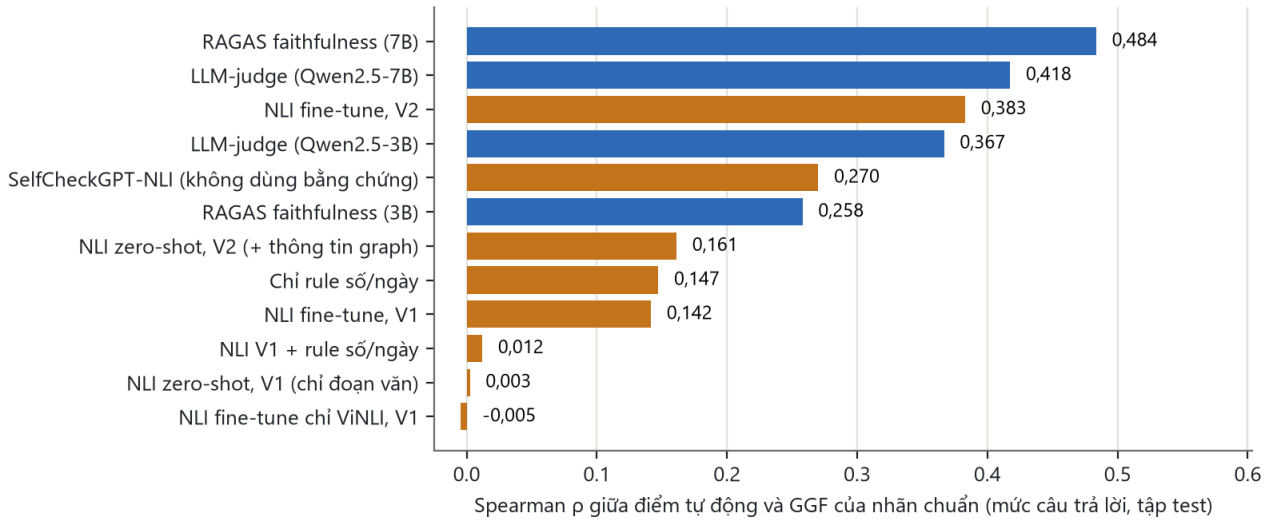
Hình 1. Macro-F1 mức claim trên tập test (nhãn silver). Xanh: LLM-judge; cam: verifier NLI; xám: SelfCheckGPT, rule và mốc tham chiếu.

Phương pháp	Macro-F1	KTC 95%	Acc	F1 sup.	F1 contra.	F1 unsup.	AUROC	n
NLI fine-tune, V1	0,521	0,44–0,60	0,656	0,77	0,38	0,41	0,738	218
NLI fine-tune V1 + rule	0,502	0,42–0,58	0,638	0,76	0,35	0,39	0,631	218
LLM-judge (Qwen2.5-7B)	0,476	0,40–0,55	0,687	0,85	0,32	0,25	0,748	217
NLI fine-tune, V2	0,465	0,39–0,54	0,633	0,78	0,23	0,38	0,735	218
NLI fine-tune V2 + rule	0,457	0,38–0,53	0,619	0,77	0,22	0,38	0,662	218
LLM-judge (Qwen2.5-3B)	0,439	0,37–0,53	0,692	0,82	0,13	0,36	0,643	214
SelfCheckGPT-NLI (không dùng bằng chứng)	0,409	0,34–0,48	0,463	0,57	0,40	0,26	0,600	218
NLI fine-tune chỉ ViNLI, V1	0,405	0,33–0,47	0,624	0,77	0,34	0,11	0,649	218
NLI zero-shot, V1 (chỉ đoạn văn)	0,404	0,33–0,47	0,592	0,74	0,31	0,17	0,545	218
NLI V1 + rule số/ngày	0,401	0,33–0,47	0,587	0,73	0,30	0,17	0,534	218
NLI chỉ ViNLI V1 + rule	0,396	0,33–0,46	0,610	0,75	0,33	0,11	0,546	218

NLI fine-tune chỉ ViNLI, V2	0,332	0,28–0,38	0,619	0,77	0,23	0,00	0,644	218
NLI zero-shot, V2 (+ thông tin graph)	0,329	0,27–0,39	0,693	0,82	0,17	0,00	0,534	218
NLI chỉ ViNLI V2 + rule	0,326	0,28–0,37	0,606	0,76	0,22	0,00	0,516	218
NLI V2 + rule số/ngày	0,322	0,27–0,38	0,679	0,81	0,15	0,00	0,520	218
Luôn đoán supported	0,275	0,26–0,29	0,702	0,82	0,00	0,00	0,500	218
Chỉ rule số/ngày	0,274	0,26–0,29	0,688	0,82	0,00	0,00	0,513	218

AUROC: khả năng xếp hạng claim không supported cao hơn claim supported (NLI dùng 1 − P(entail); phương pháp khác dùng nhãn cứng). LLM-judge thiếu nhãn ở vài claim do lỗi định dạng đầu ra nên n nhỏ hơn.

Mức câu trả lời. RAGAS faithfulness (7B) tương quan cao nhất với GGF của nhãn chuẩn (ρ = 0,484). Mô hình 7B tương quan cao hơn 3B ở cả RAGAS (ρ 0,484 so với 0,258) và LLM-judge (ρ 0,418 so với 0,367); với cỡ mẫu 62 câu trả lời, chênh lệch rõ nhất là ở RAGAS.



Hình 2. Tương quan Spearman giữa điểm tự động và GGF chuẩn trên các câu trả lời của tập test.

Metric	Spearman ρ	Kendall τ	Số câu trả lời
RAGAS faithfulness (7B)	0,484	0,396	62
LLM-judge (Qwen2.5-7B)	0,418	0,387	63
NLI fine-tune, V2	0,383	0,318	63
LLM-judge (Qwen2.5-3B)	0,367	0,322	61
NLI fine-tune V2 + rule	0,356	0,296	63

SelfCheckGPT-NLI (không dùng bằng chứng)	0,270	0,230	63
RAGAS faithfulness (3B)	0,258	0,214	62
NLI V2 + rule số/ngày	0,235	0,208	63
NLI zero-shot, V2 (+ thông tin graph)	0,161	0,145	63
Chỉ rule số/ngày	0,147	0,132	63
NLI fine-tune, V1	0,142	0,121	63
NLI fine-tune V1 + rule	0,131	0,115	63
NLI V1 + rule số/ngày	0,012	0,015	63
NLI zero-shot, V1 (chỉ đoạn văn)	0,003	0,007	63
NLI chỉ ViNLI V2 + rule	-0,002	0,002	63
NLI fine-tune chỉ ViNLI, V1	-0,005	0,000	63
NLI chỉ ViNLI V1 + rule	-0,017	-0,014	63
NLI fine-tune chỉ ViNLI, V2	-0,029	-0,019	63

6.3 RQ2: verifier dùng graph, rule số/ngày và fine-tune

Thêm thông tin graph (V2) làm giảm macro-F1 của verifier NLI từ 0,404 xuống 0,329. Ngưỡng tối ưu của V2 rất thấp ($\tau_s = 0,15$): khi thêm tên văn bản vào đầu mỗi cửa sổ, mô hình NLI gần như luôn cho xác suất entailment cao với claim nhắc tới văn bản đó, nên mất khả năng tách claim đúng và sai. Rule số/ngày gần như không đổi kết quả (V1: 0,404 → 0,401; V2: 0,329 → 0,322); một nguyên nhân là nhiều lỗi trong dữ liệu không nằm ở con số mà ở việc gán sai chủ thể (ví dụ nhiệm vụ của Văn phòng Bộ bị gán cho Viện Chiến lược và Chính sách y tế).

Fine-tune và ablation. Trên dev của verifier, fine-tune với ViNLI + cặp tổng hợp nâng độ chính xác từ 0,758 lên 0,793 (ViNLI) và từ 0,545 lên 0,875 (cặp tổng hợp); bản chỉ dùng ViNLI đạt 0,798 và 0,588. Trên tập test của đề tài, fine-tune V1 đạt 0,521, hơn zero-shot (chênh 0,117, KTC 95% [0,03; 0,20]), trong khi bản chỉ ViNLI đạt 0,405, ngang zero-shot (chênh 0,002, KTC 95% [-0,06; 0,06]). Vậy phần cải thiện đến từ **dữ liệu tổng hợp trong miền** (đổi số/ngày, phủ định, câu cùng văn bản), không phải từ thêm dữ liệu NLI tiếng Việt chung. Fine-tune cũng giảm thiệt hại của V2 (0,465 so với 0,329 ở zero-shot) nhưng V2 vẫn kém V1. So với judge 7B, fine-tune V1 cao hơn nhưng chưa có ý nghĩa (chênh 0,047, KTC 95% [-0,06; 0,16]); và như mục 4.1 cho thấy, ưu thế này không giữ được trên mẫu nhãn người.

So sánh (macro-F1, tập test)	**Hiệu số**	**KTC 95% bootstrap ghép cặp**	**Tỉ lệ mẫu bootstrap ≤ 0**	**n**
NLI fine-tune V1 − LLM-judge 7B	0,047	-0,06–0,16	0,188	217
NLI fine-tune V1 − NLI zero-shot V1	0,117	0,03–0,20	0,006	218

NLI fine-tune V1 − fine-tune chỉ ViNLI V1	0,115	0,05–0,18	0,000	218
Fine-tune chỉ ViNLI V1 − zero-shot V1	0,002	-0,06–0,06	0,475	218
NLI fine-tune V1 − fine-tune V2	0,056	-0,01–0,12	0,056	218
LLM-judge 7B − SelfCheckGPT-NLI	0,065	-0,05–0,17	0,120	217

Ghi chú tái lập. Checkpoint mDeBERTa được lưu ở float16. Các lần fine-tune đầu tiên trên Colab (transformers 5.x giữ nguyên dtype của checkpoint) huấn luyện ở fp16 thuần nên loss = NaN ngay từ đầu; checkpoint "tốt nhất" khi đó chính là mô hình gốc. Bản báo cáo trước vì vậy đã kết luận nhầm rằng fine-tune không giúp ích. Mã hiện tại ép float32, dừng khi loss không hữu hạn, và mọi điểm verifier (kể cả zero-shot) được chấm lại bằng float32.

6.4 RQ3: verify-then-revise

	Được sửa	GGF	CR	UR	Token F1	Số claim/câu	p (GGF)	p (F1)
Cả hai hệ	42/80	0,755 → 0,830	0,088 → 0,041	0,157 → 0,129	0,595 → 0,563	3,55 → 2,44	0,014	0,001
Naive RAG	22/40	0,707 → 0,810	0,118 → 0,056	0,175 → 0,134	0,601 → 0,552	3,35 → 2,38	0,033	0,003
GraphRAG	20/40	0,802 → 0,849	0,060 → 0,027	0,139 → 0,124	0,590 → 0,574	3,75 → 2,50	0,232	0,165

GGF/CR/UR do judge 7B chấm, trên các câu trả lời còn claim sau khi sửa (73/80); p: Wilcoxon cặp trên các câu trả lời được sửa. Token F1 so với đáp án chuẩn của ViHERMES, trên cả 80 câu trả lời.

42/80 câu trả lời có claim bị gắn cờ và được viết lại, trung bình 1,7 vòng. GGF tăng từ 0,755 lên 0,830 và tỉ lệ claim mâu thuẫn giảm từ 0,088 xuống 0,041. Nhưng chất lượng trả lời giảm: token F1 từ 0,595 xuống 0,563 (p = 0,001), số claim mỗi câu từ 3,55 xuống 2,44, và 7 câu trả lời chuyển thành "không tìm thấy thông tin". Bộ sinh 3B chủ yếu **xóa** claim bị gắn cờ thay vì sửa đúng theo bằng chứng. Mức tăng GGF là **giới hạn trên**: chính judge 7B vừa gắn cờ vừa chấm lại, nên câu trả lời mới được tối ưu theo đúng thước đo đó. Câu trả lời đã sửa chưa được người gán nhãn. Hiệu quả rõ hơn ở Naive RAG (GGF 0,707 → 0,810, p = 0,033) so với GraphRAG (0,802 → 0,849, p = 0,232), vì GraphRAG ban đầu ít claim sai hơn theo judge.

Ablation số vòng sửa. Cùng dữ liệu, dừng vòng lặp sau vòng 1 hoặc cho phép vòng 2:

Cấu hình	GGF	CR	UR	Token F1	Token recall	EM	Số claim/câu	Từ chối
Không sửa	0,755	0,088	0,157	0,595	0,591	0,000	3,55	0
Tối đa 1 vòng	0,801	0,059	0,140	0,569	0,545	0,000	2,75	6
Tối đa 2 vòng	0,830	0,041	0,129	0,563	0,535	0,000	2,44	7

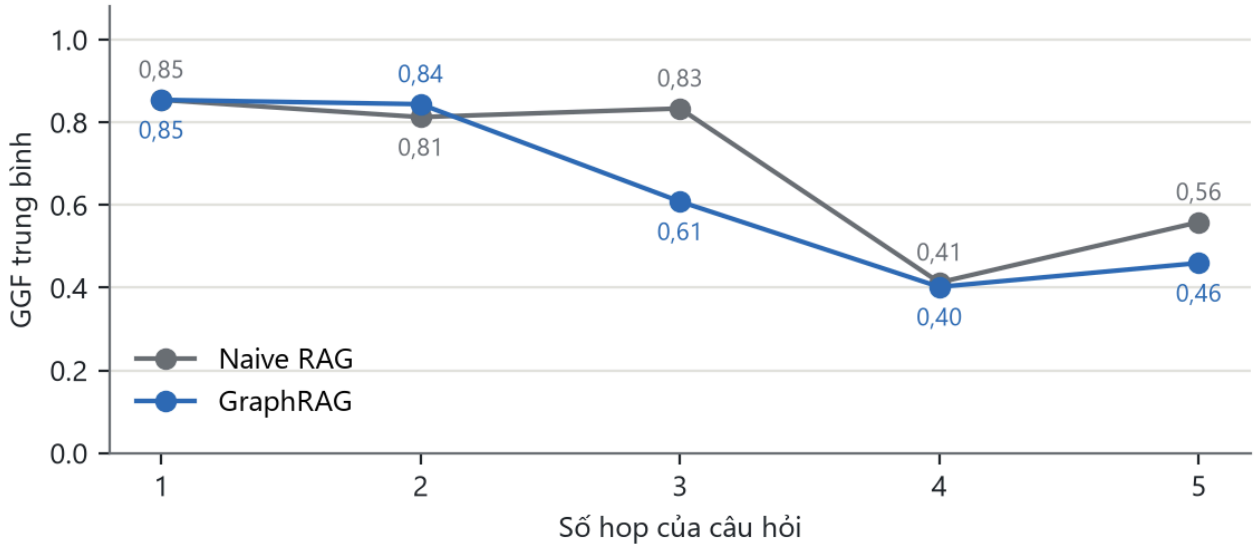
"Không sửa" tính GGF trên các câu trả lời được chấm ở cấu hình 2 vòng. Token recall = tỉ lệ từ của đáp án chuẩn có trong câu trả lời.

Vòng 1 mang lại phần lớn mức tăng GGF (0,755 → 0,801). 28 câu trả lời vẫn còn claim bị gắn cờ sau vòng 1 và đi tiếp vòng 2; trên 27 câu còn chấm được ở cả hai vòng, vòng 2 nâng GGF từ 0,491 lên 0,540 và giảm CR từ 0,162 xuống 0,111, nhưng chưa có ý nghĩa thống kê (Wilcoxon p = 0,312); token F1 giảm tiếp 0,529 → 0,511 (p = 0,144). Mỗi vòng thêm vừa bớt claim sai vừa bớt nội dung. **EM bằng 0,000 ở mọi cấu hình**, vì đáp án của ViHERMES là đoạn văn dài (trung bình khoảng 115 từ) nên không câu trả lời nào trùng khớp hoàn toàn. Vì vậy EM không dùng được cho bộ dữ liệu này; token recall cho thấy rõ hơn mức mất nội dung (0,591 → 0,545 → 0,535).

6.5 So sánh hai hệ và theo số hop

Hệ	Số câu trả lời	GGF	CR (contradicted)	UR (unsupported)
Naive RAG	40	0,694	0,182	0,124
GraphRAG	39	0,638	0,199	0,163

Khác biệt GGF giữa hai hệ không có ý nghĩa thống kê (Wilcoxon cặp, p = 0,191). Độ trung thực giảm rõ ở câu hỏi 4–5 hop:



Hình 3. GGF trung bình theo số hop (8 câu hỏi mỗi mức, mỗi hệ).

7. Phân tích lỗi

Loại lỗi	Ví dụ (claim → bằng chứng)
Sai mốc thời gian	"Luật sửa đổi Luật Dược trình Quốc hội tháng 10/2025" → tờ trình ghi "trình Quốc hội vào tháng 10 năm 2022"; mốc 10/2025 là của Luật An toàn thực phẩm.

Gán sai chủ thể	Nhiệm vụ truyền thông CCHC, quản lý Cổng TTĐT của Văn phòng Bộ bị gán cho Viện Chiến lược và Chính sách y tế.
Sai phép so sánh, tổng hợp	"Tổng mức phạt của nhóm phòng khám là 8 triệu" trong khi riêng một phòng khám đã bị phạt 30 triệu.
Từ chối sai	"Không có thông tin về thông tư phân nhóm thiết bị y tế" trong khi bằng chứng ghi rõ hiệu lực 01/01/2026.
Lỗi do bước tách claim	Claim đảo nghĩa ("cử tri kiến nghị phải tham gia BHYT tại trường học"), chèn tên người không có trong câu trả lời, câu dẫn không có nội dung (15 claim lỗi).

8. Hạn chế

- **Nguồn nhãn:** nhãn silver do Claude gán; một mẫu kiểm định mù 60 claim do người gán cho $\kappa = 0{,}29$. Đồng thuận Claude–người thấp, nên số tuyệt đối của RQ1 chỉ là ước lượng; mẫu kiểm định chỉ có 60 claim (thêm 105 claim ở các lượt nhanh) và một người gán (không phải chuyên gia pháp lý), nên chính nhãn người cũng có thể sai, nhất là với claim về sự vắng mặt thông tin. Chưa có người gán thứ hai nên chưa đo được độ đồng thuận giữa người với người.
- **Quy mô nhỏ:** 218 claim test và 63 câu trả lời test; khoảng tin cậy rộng, nhiều khác biệt giữa các metric chưa có ý nghĩa thống kê.
- **Mô hình nhỏ:** bộ sinh và bộ tách claim là Qwen2.5-3B do giới hạn phần cứng (GPU cá nhân 4GB không ổn định, phải dùng Colab miễn phí); judge lớn nhất là 7B.
- **RAGAS tái hiện:** dùng lại hai prompt gốc nhưng không dùng thư viện ragas, và chạy trên tập bằng chứng chung thay vì chỉ ngữ cảnh truy xuất.
- **Graph thô:** graph phát hành của ViHERMES chỉ gắn đoạn với văn bản và một ít quan hệ trích bằng regex, nên RQ2 chỉ kiểm tra loại thông tin graph này.
- **Fine-tune học theo nhãn silver:** ngưỡng được chọn theo nhãn Claude, và trên mẫu nhãn người verifier fine-tune kém judge 7B; cần chọn ngưỡng và đánh giá lại trên nhãn người trước khi kết luận verifier fine-tune tốt hơn. Dữ liệu tổng hợp lấy từ cùng corpus (trừ các đoạn của mẫu đánh giá), nên có thể quá khớp với văn phong của ViHERMES.
- **Verify-then-revise tự chấm:** câu trả lời đã sửa chỉ được chấm bằng judge đã gắn cờ, chưa có nhãn người hay metric độc lập ngoài token F1.
- **Một miền:** chỉ văn bản pháp quy y tế (ViHERMES).
- **Phần đề cương chưa làm** (thu hẹp theo quy mô pilot): bộ quy chế đào tạo ViEduReg; 5 hệ được đánh giá (mới có 2: Naive RAG và GraphRAG, chưa có LightRAG/HippoRAG/KAG); verifier dựa trên Qwen fine-tune; tích hợp như một toán tử Verify trong pipeline KAG; hai người gán độc lập và κ giữa người với người.

9. Kết luận

Trên dữ liệu pháp quy y tế tiếng Việt, các metric faithfulness tự động chạy bằng LLM mở cỡ nhỏ chỉ khớp ở mức thấp đến trung bình với nhãn chuẩn. **RQ1:** trong các metric có sẵn, LLM-judge 7B tốt nhất ở mức claim và RAGAS 7B tốt nhất ở mức câu trả lời; mô hình 7B tốt hơn 3B; SelfCheckGPT không thay được metric có bằng chứng. **RQ2:** fine-tune verifier với dữ liệu tổng hợp trong miền là thay đổi duy nhất có ích rõ (ablation chỉ ViNLI không cải thiện), còn thông tin graph dạng văn bản và rule số/ngày không giúp. Tuy nhiên, kiểm định mù cho thấy ưu thế của verifier fine-tune phụ thuộc vào nhãn silver (κ Claude–người = 0,29, thứ hạng metric ρ = 0,47). **RQ3:** vòng kiểm chứng rồi sửa giảm claim sai theo judge nhưng làm câu trả lời ngắn và kém đầy đủ hơn; với bộ sinh 3B, đó là đánh đổi chứ chưa phải cải thiện thuần. Hướng tiếp theo: gán nhãn người đầy đủ với hai người (có chuyên môn pháp lý) và bước thống nhất bất đồng, chọn ngưỡng verifier trên nhãn người, dùng judge ≥14B và bộ sinh lớn hơn cho bước sửa, chấm câu trả lời đã sửa bằng người hoặc một metric độc lập, và thử verifier đọc triple có cấu trúc thay vì chuỗi văn bản.

Tài liệu tham khảo

1. Es, S. và cs. RAGAS: Automated Evaluation of Retrieval Augmented Generation. EACL 2024 Demo. arXiv:2309.15217.
2. Nguyen, L. S. T. và cs. ViHERMES: A Graph-Grounded Multihop QA Benchmark and System for Vietnamese Healthcare Regulations. ACIIDS 2026. arXiv:2602.07361. github.com/ura-hcmut/ViHERMES.
3. Liang, L. và cs. KAG: Boosting LLMs in Professional Domains via Knowledge Augmented Generation. WWW 2025. arXiv:2409.13731.
4. Guo, Z. và cs. LightRAG. arXiv:2410.05779. · Gutiérrez, B. J. và cs. HippoRAG 2. arXiv:2502.14802.
5. Mickus, T. và cs. SemEval-2024 Task 6: SHROOM. arXiv:2403.07726.
6. DSC2025 ViHallu. arXiv:2601.04711. · VLUE (gồm ViNLI). arXiv:2403.15882.
7. Laurer, M. và cs. mDeBERTa-v3-base-xnli-multilingual-nli-2mil7. Hugging Face.
8. Manakul, P., Liusie, A., Gales, M. SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. EMNLP 2023. arXiv:2303.08896.

Phụ lục A: đối chiếu với đề cương Project 4

Mỗi hạng mục của đề cương ViKAG-Faith và phần đề tài pilot đã thực hiện: 20 hạng mục đạt, 14 hạng mục làm một phần hoặc thu nhỏ quy mô, 5 hạng mục chưa làm. Các phần thu nhỏ chủ yếu liên quan đến quy mô dữ liệu, số hệ thống, số người gán nhãn và kích thước mô hình (giới hạn phần cứng Colab T4), như đã nêu ở mục 8.

Hạng mục đề cương	Trạng thái	Thực hiện trong đề tài
Phương pháp		
Tách claim bằng LLM 7B, prompt tiếng Việt có ví dụ	**Một phần**	Prompt tiếng Việt có ví dụ; dùng Qwen2.5-3B thay vì 7B

Rule kiểm tra mỗi claim một vị từ chính	**Một phần**	Quy tắc nằm trong prompt; rule chỉ đánh dấu claim chứa nhiều giá trị số
Căn chỉnh claim với triple KG (entity linking), chunk gốc, top-k chunk	**Một phần**	Bằng chứng = đoạn truy xuất ∪ đoạn vàng + thông tin graph mức văn bản; chưa có entity linking/triple riêng cho từng claim
Verifier cross-encoder fine-tune ViNLI + dữ liệu tổng hợp	**Đạt**	mDeBERTa-v3-base (thay PhoBERT-large/XLM-R), 12.000 cặp ViNLI + 3.328 cặp tổng hợp
Verifier Qwen 1.5–4B trả nhãn và span bằng chứng	**Chưa làm**	
Rule số/ngày	**Đạt**	So với văn bản bằng chứng, chưa so với thuộc tính KG
Metric GGF, CR, UR	**Đạt**	Mục 3.2, 6.4, 6.5
Verify-then-revise, tối đa 2 vòng	**Đạt**	Mục 3.4, 6.4
Câu hỏi nghiên cứu		
RQ1: RAGAS, LLM-judge tương quan với người	**Một phần**	Đo đầy đủ trên nhãn silver; nhãn người có 165 claim (mục 4.1)
RQ2: bằng chứng graph so với chỉ chunk	**Một phần**	V1 so với V2; graph đưa vào dạng văn bản, chưa phải triple
RQ3: revise giảm claim sai mà không giảm F1	**Đạt**	Giảm claim sai theo judge nhưng F1 giảm (mục 6.4)
Dữ liệu		
Câu hỏi ViHERMES	**Đạt**	100 câu, 20 câu mỗi mức hop
ViEduReg (~500 câu quy chế đào tạo)	**Chưa làm**	
5 hệ thống × ~600 câu	**Một phần**	2 hệ (Naive RAG, GraphRAG) × 100 câu
~3.000 claim gán nhãn	**Một phần**	284 claim trong mẫu, nhãn silver
3 nhãn + span bằng chứng	**Một phần**	Đủ 3 nhãn; bằng chứng ở mức số đoạn, chưa có span
2–3 người gán, báo cáo κ	**Một phần**	1 người, 165 claim (2 lượt mù); chỉ có κ Claude–người
~20% làm dev	**Đạt**	51 claim dev, 218 claim test
ViNLI >30K + ~20K cặp tổng hợp	**Một phần**	12.000 + 3.328 cặp
Thiết lập thực nghiệm		
Baseline RAGAS với LLM mở	**Đạt**	Qwen2.5-3B/7B
Baseline LLM-judge Qwen2.5-32B-AWQ (hoặc 14B)	**Một phần**	Qwen2.5-3B/7B do phần cứng Colab T4
Baseline SelfCheckGPT	**Đạt**	SelfCheckGPT-NLI, 3 mẫu
Baseline NLI zero-shot đa ngôn ngữ	**Đạt**	mDeBERTa-v3-base-xnli

Baseline hệ tốt nhất của ViHallu (nếu có mã nguồn)	**Chưa làm**	
Metric verifier: macro-F1, AUROC	**Đạt**	Mục 6.2, kèm KTC bootstrap và kiểm định ghép cặp
Spearman/Kendall với người	**Một phần**	Tính với nhãn silver; mẫu người không đủ cho mức câu trả lời
Metric revise: thay đổi GGF và F1/EM	**Đạt**	GGF, token F1, EM (= 0, xem 6.4), thêm token recall
Ablation		
Bỏ triple	**Đạt**	V1 so với V2
Bỏ rule số/ngày	**Đạt**	Biến thể + rule
Encoder so với LLM nhỏ	**Một phần**	mDeBERTa so với LLM-judge 3B/7B; chưa fine-tune LLM nhỏ
Có/không dữ liệu tổng hợp	**Đạt**	Fine-tune chỉ ViNLI (mục 6.3)
Số vòng revise	**Đạt**	1 vòng so với 2 vòng (mục 6.4)
Đóng góp và sản phẩm		
Bộ ViFaithKAG	**Một phần**	Bản pilot: dataset/ViFaithKAG (claims, answers, passages JSONL)
Verifier nhỏ	**Đạt**	mDeBERTa fine-tune
Meta-evaluation metric tự động trên tiếng Việt	**Đạt**	Mục 6.2, 4.1
Module cắm vào KAG solver như toán tử Verify	**Chưa làm**	
Paper và demo	**Đạt**	Báo cáo này và trang demo tương tác
Chatbot quy chế cho trường	**Chưa làm**	Phụ thuộc ViEduReg
Rủi ro: báo cáo riêng kết quả trên claim thật	**Đạt**	Dữ liệu tổng hợp chỉ dùng để huấn luyện

Phụ lục B: tái lập

Mã nguồn: `vikag-faith/src` (s1_answer → s2_claims → s3_pool → s4_judges → s5_verifier → s8_revise, s9_selfcheck → s6_annotation → s7_analysis), notebook Colab sinh bởi `make_colab.py`, báo cáo sinh bởi `make_report.py`, trang demo bởi `make_demo.py` (https://claude.ai/artifact/WpaWPBgdzeQgxe9jmwVeQ4), bộ dữ liệu `dataset/ViFaithKAG` bởi `make_dataset.py`. Seed 42. Mọi số liệu trong báo cáo đọc từ `outputs/analysis/results.json`.