ĐỒ ÁN P4 · XỬ LÝ NGÔN NGỮ TỰ NHIÊN NÂNG CAO

Đánh giá tính trung thực mức mệnh đề cho hệ hỏi đáp GraphRAG tiếng Việt



ViKAG-Faith: Graph-Grounded Claim-Level Faithfulness Evaluation and Verification for Vietnamese Knowledge-Augmented Generation

Hà Văn Vinh

Học viên cao học · Xử lý ngôn ngữ tự nhiên nâng cao

Tóm tắt

Máy kiểm tra giúp được, nhưng chưa thay được người kiểm tra

0,528 1

macro-F1 của LLM-judge 7B theo nhãn người (165 claim): metric đáng tin nhất; RAGAS 7B tốt nhất ở mức câu trả lời (ρ = 0,484) (RQ1)

0,404 → 0,521 2

fine-tune verifier bằng dữ liệu tổng hợp theo nhãn silver; theo nhãn người chỉ 0,381 so với 0,409 (RQ2)

8,8% → 4,1% 3

claim mâu thuẫn sau verify-then-revise; nhưng token F1 giảm 0,595 → 0,563: AI xóa ý thay vì sửa (RQ3)

65% · κ = 0,29 !

mức trùng giữa nhãn Claude (silver) và 165 nhãn người qua 5 lượt gán mù; Claude khắt khe hơn người

Bối cảnh

Một con số hay một ngày sai là đủ gây hậu quả với văn bản pháp quy

- GraphRAG/KAG tiếng Việt hiện được chấm bằng F1 hoặc một điểm LLM-judge cho cả câu trả lời.
- Không điểm nào chỉ ra mệnh đề nào bịa thêm hay mâu thuẫn với bằng chứng.
- ViHERMES (ACIIDS 2026): bỏ module kiểm chứng làm điểm judge giảm 0,7554 → 0,6823.
- Các metric faithfulness (RAGAS, LLM-judge, SelfCheckGPT) chủ yếu được kiểm định trên tiếng Anh.

Ví dụ từ dữ liệu

Claim

“Luật sửa đổi Luật Dược trình Quốc hội tháng 10/2025”

Bằng chứng

Tờ trình ghi “trình Quốc hội vào tháng 10 năm 2022”; mốc 10/2025 là của Luật An toàn thực phẩm.

contradicted

Câu hỏi nghiên cứu và đóng góp

Không xây hệ hỏi đáp mới: đánh giá các công cụ kiểm chứng trên tiếng Việt

Câu hỏi nghiên cứu

RQ1 Metric có sẵn (RAGAS, LLM-judge, SelfCheckGPT, NLI) khớp với nhãn chuẩn đến đâu?

RQ2 Thông tin đồ thị, rule số/ngày, fine-tune bằng dữ liệu tổng hợp có giúp verifier không?

RQ3 Verify-then-revise giảm claim sai bao nhiêu, có làm giảm chất lượng trả lời không?

Hướng tiếp cận: tách câu trả lời thành claim, đối chiếu với tập bằng chứng chung, đo mức khớp của từng metric với nhãn chuẩn (meta-evaluation).

Đóng góp

C1 · Quy trình: đánh giá mức claim tái lập được trên ViHERMES (7 bước, Colab T4)

C2 · Dữ liệu: ViFaithKAG pilot: 284 claim nhãn silver, 165 claim nhãn người

C3 · Meta-evaluation: 12 biến thể metric + ablation đồ thị, rule, dữ liệu tổng hợp, số vòng sửa

C4 · Độ tin cậy nhãn: nhãn LLM so với người: thứ hạng metric đổi khi đổi bộ nhãn

Công trình liên quan

Các metric hiện có chưa được kiểm định ở mức claim cho tiếng Việt

1 Đo faithfulness của RAG

RAGAS: tỉ lệ statement suy ra được từ ngữ cảnh. FActScore: chấm từng atomic fact. LLM-as-a-judge.

→ Kiểm định chủ yếu trên tiếng Anh.

2 Phát hiện hallucination

SelfCheckGPT (không cần bằng chứng), SemEval SHROOM/Mu-SHROOM, DSC2025 ViHallu.

→ ViHallu không gắn với đồ thị hay bằng chứng truy xuất.

3 NLI tiếng Việt

XNLI, ViNLI; mDeBERTa-v3 huấn luyện NLI đa ngôn ngữ làm verifier encoder.

→ Chưa có dữ liệu claim–bằng chứng pháp quy.

4 Graph RAG và KAG

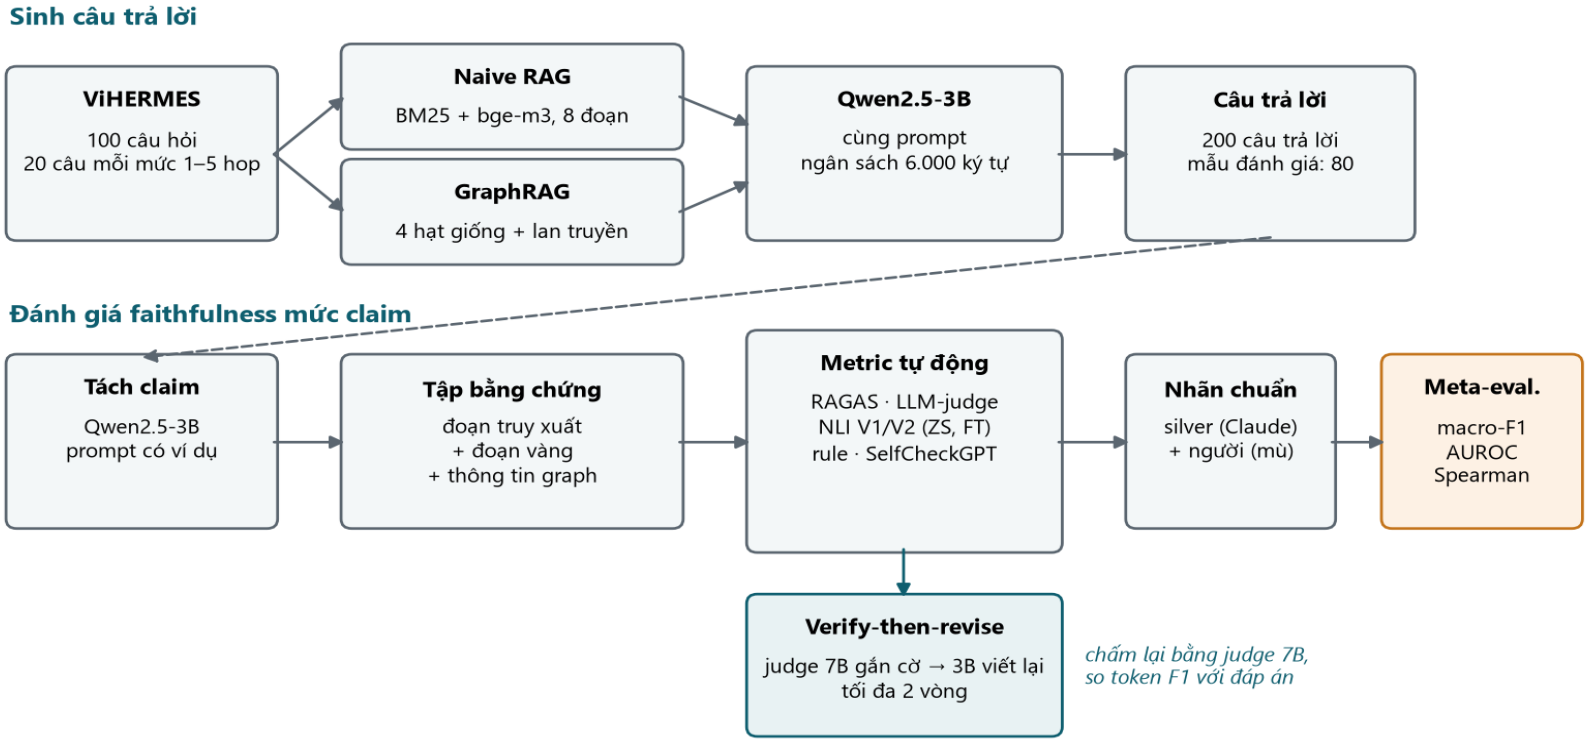
GraphRAG, LightRAG, HippoRAG 2, KAG; ViHERMES dựng đồ thị Văn bản–Điều–Khoản.

→ Nền dữ liệu và đồ thị mà đề tài dùng lại.

Vị trí của đề tài: đánh giá các metric kiểm chứng ở mức claim, có so với nhãn người; giữ nguyên dữ liệu và đồ thị ViHERMES, chỉ thêm tầng đánh giá.

Kiến trúc hệ thống

Hai hệ sinh câu trả lời → tách claim → tập bằng chứng chung → metric → so với nhãn chuẩn



Tách claim và tập bằng chứng

Mọi metric và người gán nhìn cùng một tập bằng chứng

1 Hai hệ hỏi đáp

Naive RAG (8 đoạn) và GraphRAG (4 hạt giống + lan truyền đồ thị ViHERMES); cùng BM25 + bge-m3, Qwen2.5-3B, 6.000 ký tự.

2 Tách claim

Qwen2.5-3B, prompt tiếng Việt có ví dụ: một vị từ chính, tự hiểu được, giữ nguyên số, ngày, số hiệu.

3 Tập bằng chứng

Đoạn truy xuất ∪ đoạn vàng của ViHERMES, kèm tên văn bản, số hiệu và quan hệ lấy từ đồ thị.

4 Ba nhãn

supported: suy ra được · contradicted: nói ngược lại · unsupported: không đề cập. Claim tách hỏng bị loại.

610

claim tách từ 200 câu trả lời (100 câu hỏi × 2 hệ)

284

claim trong mẫu 80 câu trả lời được gán nhãn (15 claim lỗi bị loại)

Metric và verifier

Từ LLM làm giám khảo đến verifier NLI có luyện thêm

$GGF = |claim\ supported| / |claim|$ $P_sup(c) = max_w\ P(entail \mid w, c)$
$P_con(c) = max\ P(contra \mid w, c)$ trên 2 cửa sổ w trùng từ nhiều nhất với claim

CR, UR: tỉ lệ contradicted, unsupported. Cửa sổ 900 ký tự; ngưỡng (τ_s, τ_c) chọn trên tập dev.

RAGAS & LLM-judge

RAGAS tái hiện 2 prompt gốc; judge gán 3 nhãn cho từng claim. Qwen2.5-3B và 7B.

NLI V1 / V2

mDeBERTa-v3 zero-shot. V1: chỉ đoạn văn; V2: thêm tên văn bản, số hiệu, quan hệ đồ thị.

Fine-tune

12.000 cặp ViNLI + 3.328 cặp tổng hợp (đổi số, ngày, phủ định). Ablation: chỉ ViNLI.

Rule & SelfCheckGPT

Rule so khớp số/ngày/số hiệu. SelfCheckGPT: 3 mẫu nhiệt độ 0,7, không nhìn bằng chứng.

Dữ liệu và nhãn

Nhãn chính là silver; 165 claim được người gán mù qua 5 lượt

Lượt	Cách chọn · hiển thị	Claim	Trùng Claude	κ
C	phân tầng 30/15/15 · toàn đoạn văn	60	60%	0,29
G, H, I, J	ngẫu nhiên · 4 câu bằng chứng	105	69%	0,30
Gộp		**165**	**65%**	**0,29**
Bị loại	duyệt có gợi ý; file không tạo qua trang	–	–	–

Người gán không thấy nhãn hay lý do của Claude và không biết câu trả lời thuộc hệ nào.



100

câu hỏi (20 mỗi mức hop)

51/218

claim dev / test

165

claim có nhãn người

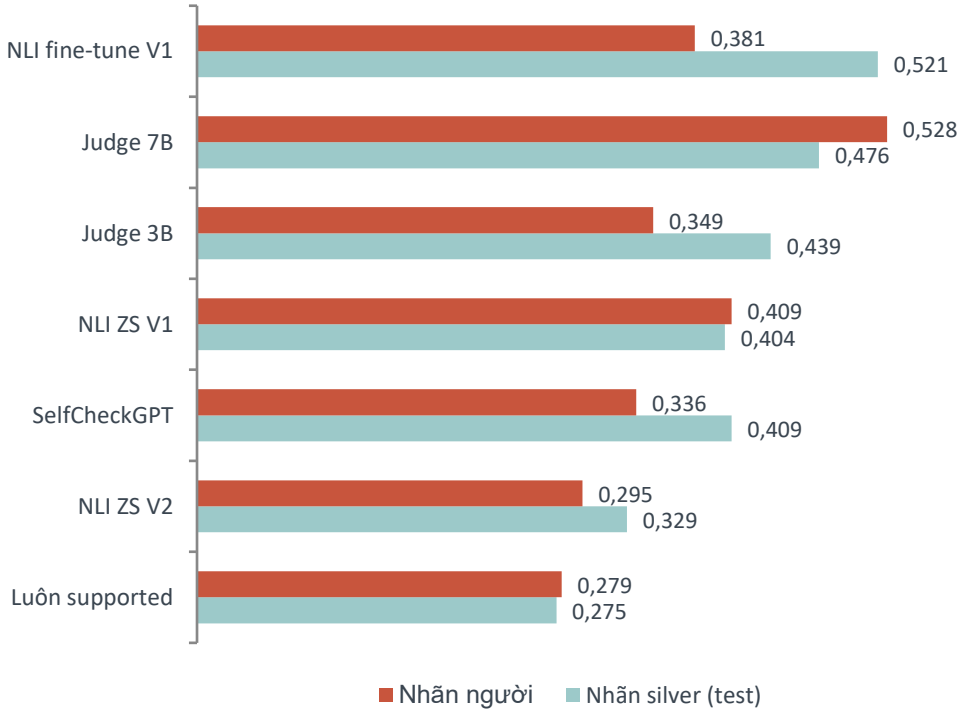
Thiết lập thí nghiệm

Mọi bước dùng mô hình chạy trên Colab T4; máy cá nhân chỉ phân tích

Cấu hình	Judge 3B/7B · RAGAS 3B/7B · NLI zero-shot V1/V2 · fine-tune V1/V2 · fine-tune chỉ ViNLI · mỗi NLI có/không rule · SelfCheckGPT · rule · luôn đoán supported
Metric	Mức claim: macro-F1 3 nhãn, AUROC phát hiện claim sai. Mức câu trả lời: Spearman/Kendall với GGF chuẩn. Revise: GGF, CR, token F1, EM, token recall
Thống kê	KTC 95% bootstrap 1.000 lần; bootstrap ghép cặp cho hiệu số; Wilcoxon cặp; Cohen's κ
Phần cứng	Google Colab T4 16GB (Ollama Q4_K_M, PyTorch float32). GPU cá nhân 4GB treo máy khi chạy mô hình

Kết quả tổng hợp

Macro-F1 trên 218 claim test (nhãn silver) và trên 165 claim có nhãn người

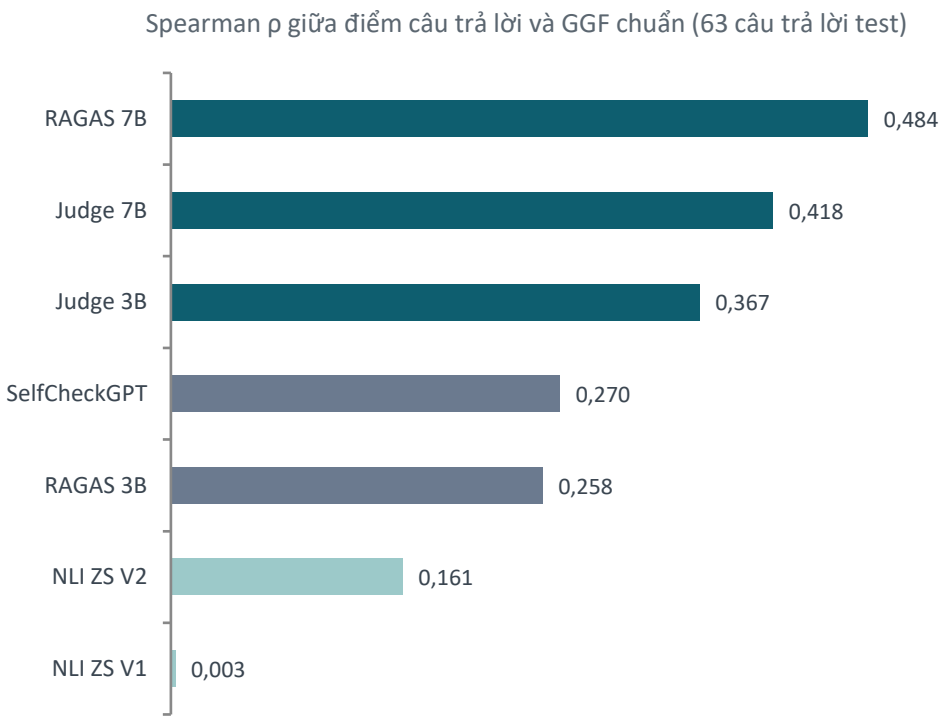


Đọc biểu đồ

- Theo nhãn silver, fine-tune V1 cao nhất.
- Theo nhãn người, judge 7B cao nhất; fine-tune tụt về mức zero-shot.
- F1 cho contradicted/unsupported của mọi metric đều dưới 0,45.

RQ1: các metric có sẵn

Judge 7B tốt nhất ở mức claim; RAGAS 7B tốt nhất ở mức câu trả lời



0,476

macro-F1 judge 7B (silver), AUROC 0,748

0,484

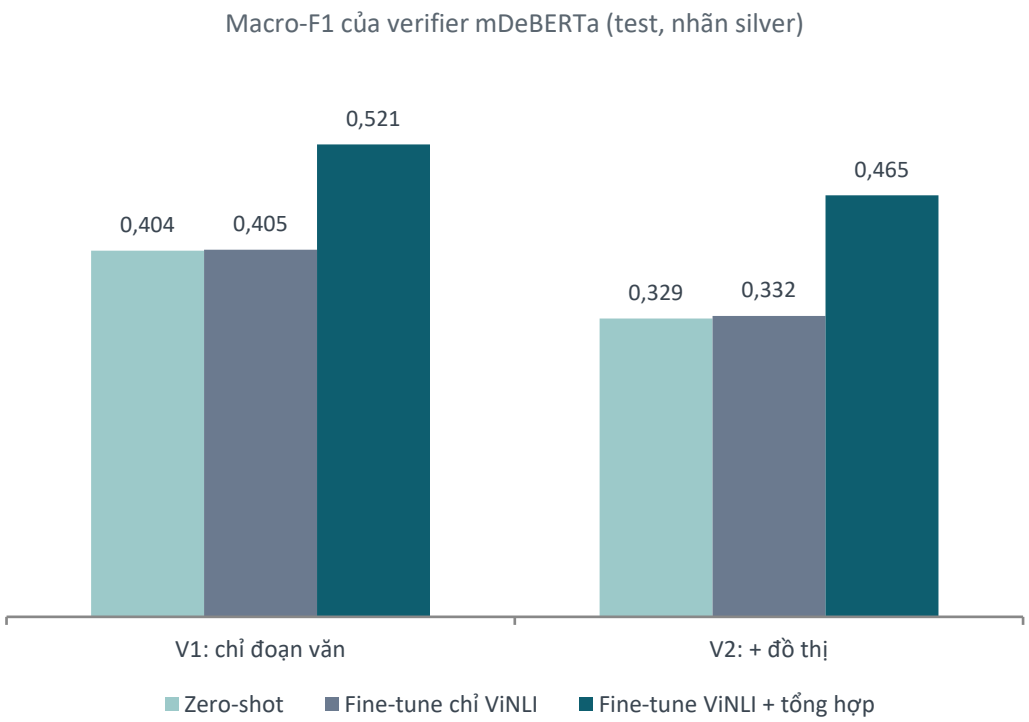
ρ RAGAS 7B; RAGAS 3B chỉ 0,258: kích thước judge quyết định

0,409

SelfCheckGPT: ngang NLI zero-shot dù không nhìn bằng chứng

RQ2: đồ thị, rule và fine-tune

Dữ liệu tổng hợp giúp theo nhãn silver; thông tin đồ thị làm kém đi



+0,117

fine-tune so với zero-shot (KTC 0,03–0,20)

+0,002

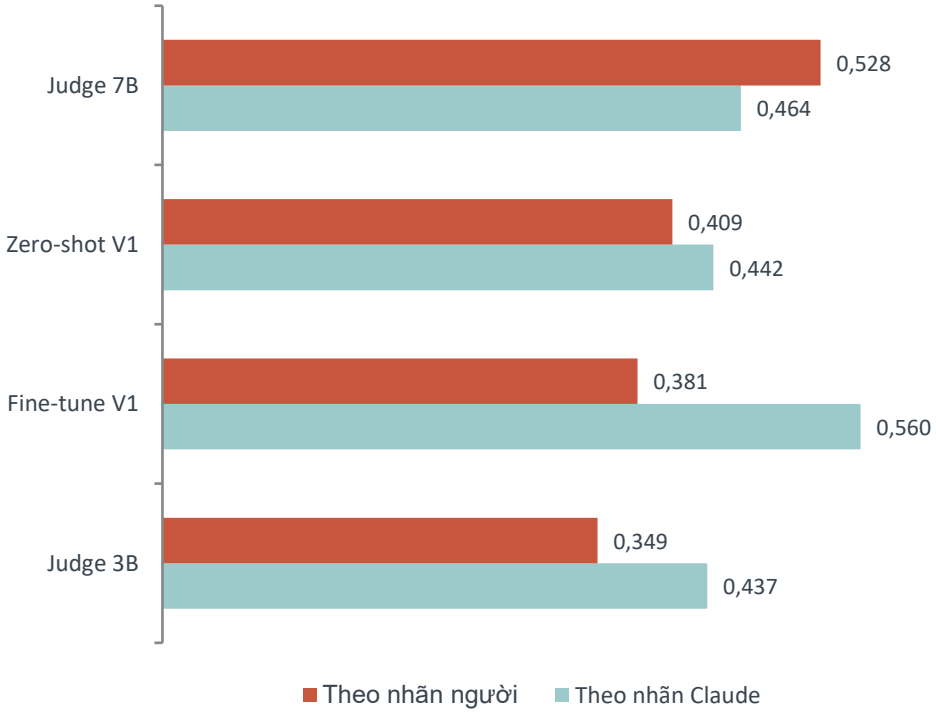
bỏ dữ liệu tổng hợp: không cải thiện

0,404 → 0,329

thêm đồ thị (V2): máy thấy tên văn bản trùng là cho supported

Kiểm định mù: nhãn người đổi thứ hạng

165 claim người gán; ưu thế của fine-tune biến mất



κ = 0,29

Claude trùng người 65%.

Claude gán sai/không căn cứ cho 59 claim; người gán supported 29 trong số đó.

Tương quan thứ hạng metric giữa hai bộ nhãn: ρ = 0,46.

RQ3: verify-then-revise

Ít claim sai hơn nhưng câu trả lời ngắn và thiếu hơn

GGF (judge 7B)

0,830

từ 0,755

Claim mâu thuẫn

0,041

từ 0,088

Token F1

0,563

từ 0,595

Claim mỗi câu

2,44

từ 3,55

42/80 câu được sửa · p(GGF) = 0,014 · p(F1) = 0,001 · 7 câu thành "không tìm thấy thông tin"

Số vòng sửa tối đa	GGF	Mâu thuẫn	Token F1	Token recall	EM
0 (không sửa)	0,755	0,088	0,595	0,591	0,000
1 vòng	0,801	0,059	0,569	0,545	0,000
2 vòng	0,830	0,041	0,563	0,535	0,000

EM = 0 vì đáp án ViHERMES dài (~115 từ). GGF do chính judge 7B chấm lại nên là giới hạn trên.

RQ3: AI xóa ý thay vì sửa

Ví dụ thật: câu hỏi 3 hop, Naive RAG, sau 1 vòng sửa

Câu hỏi: so sánh thời điểm trình Quốc hội Luật sửa đổi Luật Dược, ban hành Nghị định 124/2021 và bệnh viện tự chủ mua sắm thuốc theo Luật 90/2025.

Trước khi sửa

Dự kiến Luật sửa đổi Luật Dược sẽ được trình Quốc hội vào **tháng 10/2025**. Nghị định 124/2021/NĐ-CP … được ban hành vào tháng 12/2021. Thời điểm các bệnh viện tự chủ được tự quyết định mua sắm thuốc … là từ ngày 01/7/2025.

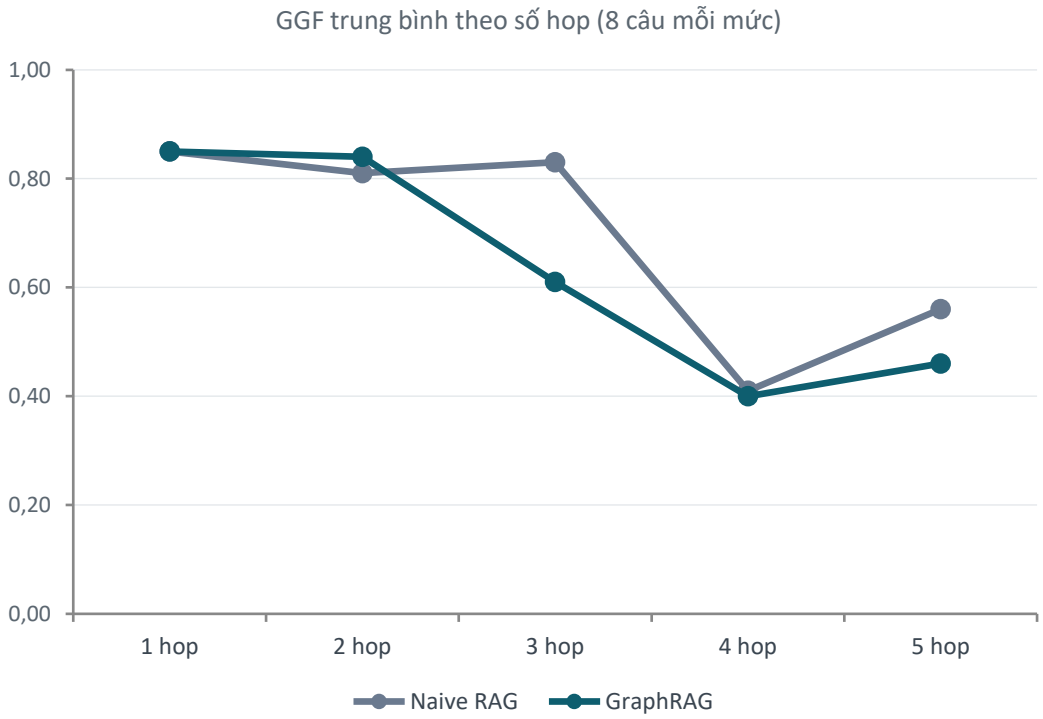
Sau 1 vòng sửa

Không tìm thấy thông tin về thời điểm dự kiến trình Quốc hội Luật sửa đổi Luật Dược. Thời điểm ban hành Nghị định 124/2021/NĐ-CP và thời điểm … mua sắm thuốc theo Luật số 90/2025/QH15 **được nêu rõ trong ngữ cảnh**.

! Văn bản ghi Luật Dược trình Quốc hội tháng 10/2022. Câu trả lời mới đạt GGF = 1 theo judge nhưng mất cả ba mốc thời gian, kể cả mốc 01/7/2025 đúng.

Hai hệ và độ khó theo hop

GGF 0,69 và 0,64 (p = 0,19); câu 4–5 hop khó hơn rõ



0,570

token F1 Naive RAG (GraphRAG 0,563)

47% · 48%

recall đoạn vàng của hai hệ: đồ thị phát hành khá thô

~0,4–0,5

GGF ở câu 4–5 hop, so với ~0,85 ở câu 1 hop

Phân tích lỗi

Nhiều lỗi nằm ở chủ thể và phép tổng hợp, không chỉ ở con số

1

Sai mốc thời gian

Ghép mốc 10/2025 của luật khác vào Luật Dược (văn bản ghi 10/2022).

2

Gán sai chủ thể

Nhiệm vụ của Văn phòng Bộ gán cho Viện Chiến lược và Chính sách y tế. Rule số/ngày không bắt được.

3

Sai phép tổng hợp

“Tổng phạt 8 triệu” trong khi một phòng khám đã bị phạt 30 triệu. Cả hai judge bỏ sót; NLI bắt được.

4

Bịa thêm danh sách

Thêm Instagram, TikTok, YouTube; văn bản chỉ ghi facebook, zalo. NLI zero-shot bị lừa.

Hạn chế và rủi ro

Mỗi hạn chế kèm hướng giảm thiểu

1 Nhãn chuẩn là silver

Claude trùng người 65%.
Giảm thiểu: báo cáo song song theo nhãn người

2 Một người gán

Không phải chuyên gia pháp lý; lượt nhanh chỉ xem 4 câu.
Giảm thiểu: hai người gán, đo κ người–người

3 Quy mô nhỏ

2 hệ, 284 claim, judge 7B (Colab T4).
Giảm thiểu: KTC bootstrap, kiểm định ghép cặp

4 Ngưỡng theo silver

Verifier fine-tune nghiêng theo Claude.
Giảm thiểu: chọn ngưỡng trên nhãn người

5 Revise tự chấm

Judge vừa gắn cờ vừa chấm lại.
Giảm thiểu: chấm bằng người hoặc metric độc lập

6 Đồ thị dạng văn bản

Chưa dùng triple; chưa có ViEduReg, toán tử Verify KAG.
Giảm thiểu: verifier đọc triple có cấu trúc

Kết luận và hướng phát triển

Công cụ kiểm tra tự động hữu ích nhưng chưa thay được người

RQ1 Judge 7B (0,528 theo người) và RAGAS 7B tốt nhất; chỉ khớp mức trung bình.

RQ2 Dữ liệu tổng hợp giúp theo nhãn silver, không giữ được theo người; đồ thị dạng văn bản và rule không giúp.

RQ3 Sửa giảm claim sai bằng cách xóa nội dung: đánh đổi, chưa phải cải thiện thuần.

Hướng phát triển

1. Nhãn người cho toàn bộ mẫu, hai người gán có chuyên môn pháp lý.
2. Judge 14–32B; verifier Qwen trả nhãn và span.
3. Đưa đồ thị vào verifier dạng triple; thêm LightRAG, KAG, ViEduReg.
4. Chấm câu trả lời đã sửa bằng người; bộ sinh lớn hơn cho bước sửa.

Số liệu test dùng nhãn silver; nhãn người: 165 claim, một người gán.

Cảm ơn thầy cô và các bạn đã lắng nghe

Hà Văn Vinh

Mã nguồn: vikag-faith (ViHERMES + tầng đánh giá) · Dữ liệu: ViFaithKAG · Demo: trang tương tác ViKAG-Faith